BAB III
PEMBAHASAN

3.1 Persiapan Data

Tahap ini diawali dengan pengumpulan data melalui Blockchain.com Charts API, kemudian seluruh *chart* digabungkan menjadi satu dataset berdasarkan tanggal. Dataset terdiri atas satu kolom tanggal dan 10 variabel, yaitu *close price* Bitcoin yang berperan sebagai variabel target (Y) sekaligus prediktor (X_1) serta sembilan variabel informasi *blockchain* (X_2 sampai X_{10}). Data mencakup periode 1 Juli 2023 hingga 31 Juli 2026 sehingga diperoleh 1.127 baris tanggal. Jumlah observasi yang berhasil diperoleh untuk setiap variabel disajikan pada Tabel 7.

Tabel 7. Jumlah Observasi per Variabel Hasil Pengumpulan Data

Kode	Variabel	*Chart* API	Jumlah Observasi	Tanggal Kosong
Y / X_1	*Close Price*	market-price	1.127	0
X_2	*Miners Revenue*	miners-revenue	1.127	0
X_3	*Difficulty*	difficulty	1.124	3
X_4	*Hash Rate*	hash-rate	1.124	3
X_5	*Median Confirmation Time*	median-confirmation-time	1.124	3
X_6	*Average Block Size*	avg-block-size	1.124	3
X_7	*Total Unique Addresses*	n-unique-addresses	1.123	4
X_8	*Transaction per Block*	n-transactions-per-block	1.124	3
X_9	*Confirmed Transaction*	n-transactions	1.124	3
X_{10}	*Cost % per Transaction*	cost-per-transaction-percent	1.122	5

Tabel 7 menunjukkan bahwa *Close Price* dan *Miners Revenue* tersedia lengkap untuk seluruh 1.127 hari, sedangkan delapan variabel lainnya kehilangan tiga sampai lima tanggal akibat celah (*gap*) pelaporan API. Nilai *Difficulty* yang sama selama beberapa hari berturut-turut bukan merupakan data hilang, melainkan sifat alami penyesuaian tingkat kesulitan setiap 2.016 blok. Sepuluh observasi pertama dataset disajikan pada Tabel 8.

Tabel 8. Sampel Dataset *Bitcoin*

Tanggal	*Close Price* (USD)	*Miners Revenue* (juta USD)	*Difficulty* ($\times 10^{12}$)	*Hash Rate* (juta TH/s)	*Median Conf. Time* (menit)	*Avg. Block Size* (MB)	*Unique Addresses* (ribu)	*Tx per Block*	*Confirmed Tx* (ribu)	*Cost % per Tx*
01/07/2023	30.471,50	26,15	50,65	334,85	9,30	1,657	622,1	2.438,2	324,3	0,832
02/07/2023	30.591,53	33,78	50,65	430,52	6,95	1,817	534,3	1.812,4	309,9	1,735
03/07/2023	30.618,25	27,99	50,65	344,92	12,63	1,780	655,4	2.395,0	328,1	0,787
04/07/2023	31.150,92	28,64	50,65	357,50	11,31	1,725	645,6	2.665,9	378,6	0,928
05/07/2023	30.774,87	30,31	50,65	390,23	9,18	1,693	716,6	3.183,7	493,5	0,994
06/07/2023	30.502,55	27,13	50,65	349,95	9,57	1,652	709,1	2.825,1	392,7	0,542
07/07/2023	29.918,04	34,01	50,65	440,59	7,75	1,799	773,3	3.177,2	556,0	1,102
08/07/2023	30.344,53	34,11	50,65	448,14	9,74	1,752	696,0	3.223,0	573,7	1,971
09/07/2023	30.214,55	33,19	50,65	425,48	10,42	1,764	732,6	3.516,4	594,3	1,933
10/07/2023	30.214,55	29,65	50,65	387,72	8,13	1,664	679,4	3.293,0	507,1	0,831

Keterangan: *Miners Revenue* dalam juta USD, *Difficulty* dalam satuan 10^{12}, *Hash Rate* dalam juta TH/s, serta *Total Unique Addresses* dan *Confirmed Transaction* dalam ribuan. Dataset lengkap disajikan pada Lampiran 1.

Statistik deskriptif seluruh variabel disajikan pada Tabel 9.

Tabel 9. Statistik Deskriptif Seluruh Variabel

Kode	Variabel (Satuan)	N	Rata-rata	Std	Min	Median	Maks	*Skew*	*Kurt*
Y / X_1	*Close Price* (USD)	1.127	73.217,85	26.310,08	25.162,70	69.331,66	124.776,68	-0,085	-0,894
X_2	*Miners Revenue* (juta USD)	1.127	40,49	11,57	19,27	39,12	107,76	0,724	0,670
X_3	*Difficulty* ($\times 10^{12}$)	1.124	105,19	30,48	50,65	109,78	155,97	-0,149	-1,214
X_4	*Hash Rate* (juta TH/s)	1.124	757,53	223,55	300,15	767,19	1.305,50	-0,030	-1,005
X_5	*Median Confirmation Time* (menit)	1.124	9,20	2,34	0,06	9,25	18,04	-0,320	1,102
X_6	*Average Block Size* (MB)	1.124	1,622	0,122	1,065	1,614	2,293	0,310	3,179
X_7	*Total Unique Addresses* (ribu alamat)	1.123	556,9	101,6	358,4	534,8	1.017,5	1,020	0,880
X_8	*Transaction per Block* (transaksi/blok)	1.124	3.356,8	811,2	1.430,2	3.250,1	5.517,9	0,281	-0,552
X_9	*Confirmed Transaction* (ribu transaksi)	1.124	488,0	129,5	242,4	464,0	927,0	0,581	-0,139
X_{10}	*Cost % per Transaction* (%)	1.122	0,794	0,576	0,066	0,557	5,826	1,801	5,823

Rata-rata dan standar deviasi harga penutupan dihitung secara manual menggunakan persamaan (1) dan (2) sebagai berikut:

$$\bar{x} = \frac{1}{1.127}(30.471,50 + 30.591,53 + 30.618,25 + \cdots + 64.720,99)$$

$$= \frac{82.516.521,90}{1.127} = 73.217,85$$

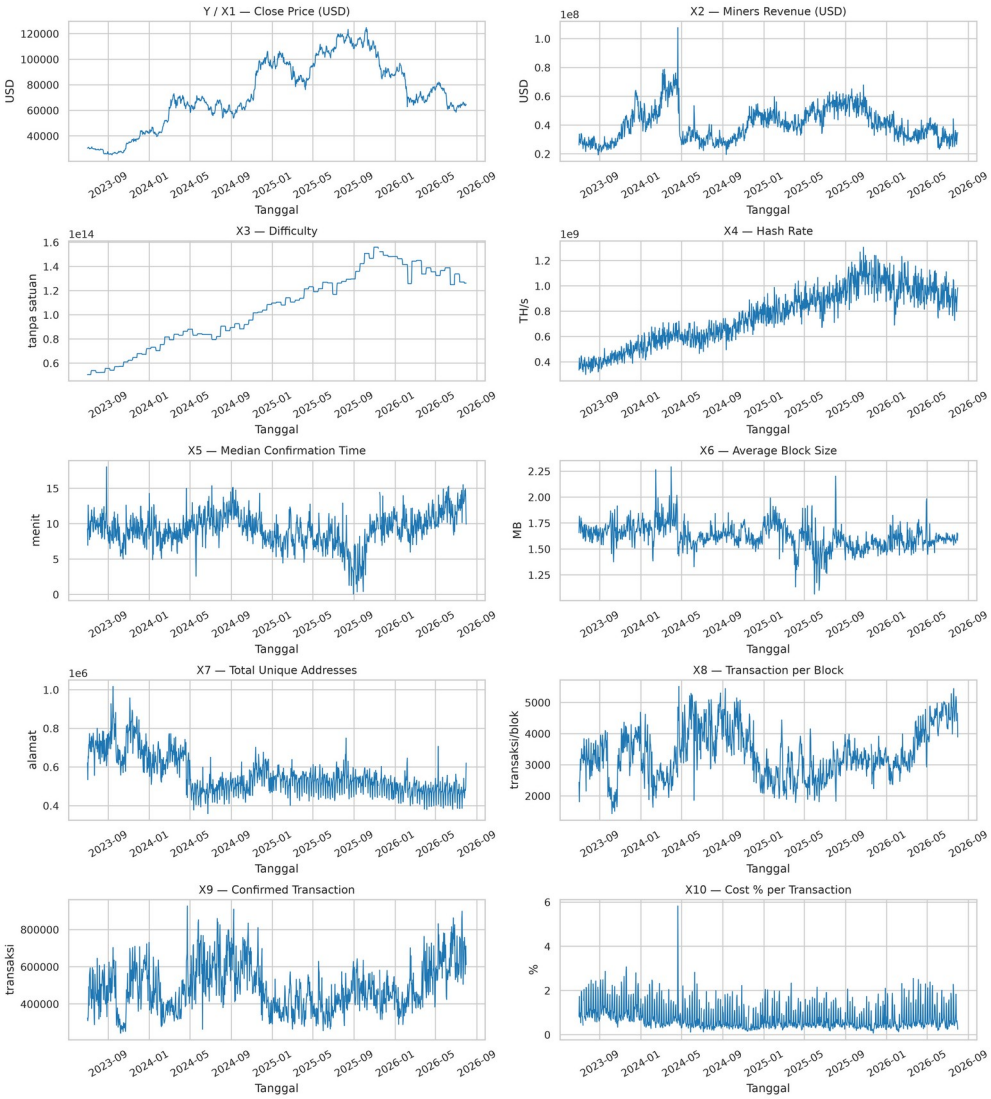
$$\sum_{i=1}^{1.127} (x_i - \bar{x})^2 = (30.471,50 - 73.217,85)^2 + (30.591,53 - 73.217,85)^2 + \cdots$$

$$= 1.827.250.813,82 + 1.817.003.531,19 + \cdots = 779.439.786.641,80$$

$$s = \sqrt{\frac{779.439.786.641,80}{1.127 - 1}} = \sqrt{692.220.059,18} = 26.310,08$$

Hasil perhitungan manual tersebut identik dengan keluaran pustaka pandas hingga toleransi 10^{-5}. Rata-rata harga penutupan selama periode penelitian adalah 73.217,85 USD dengan standar deviasi 26.310,08 USD, harga terendah 25.162,70

USD (12 September 2023), dan harga tertinggi 124.776,68 USD (7 Oktober 2025). Nilai *skewness Close Price* mendekati nol ($-0{,}085$) dengan *excess kurtosis* negatif ($-0{,}894$), yang menunjukkan sebaran harga relatif simetris dan lebih datar daripada distribusi normal karena harga bergerak melintasi rentang yang lebar. Sebaliknya, *Cost % per Transaction* memiliki *skewness* 1,801 dan *kurtosis* 5,823 yang menandakan adanya lonjakan ekstrem pada beberapa hari. Visualisasi runtun waktu seluruh variabel dapat dilihat pada Gambar 9.



Gambar 9. Visualisasi Data Tiap Atribut

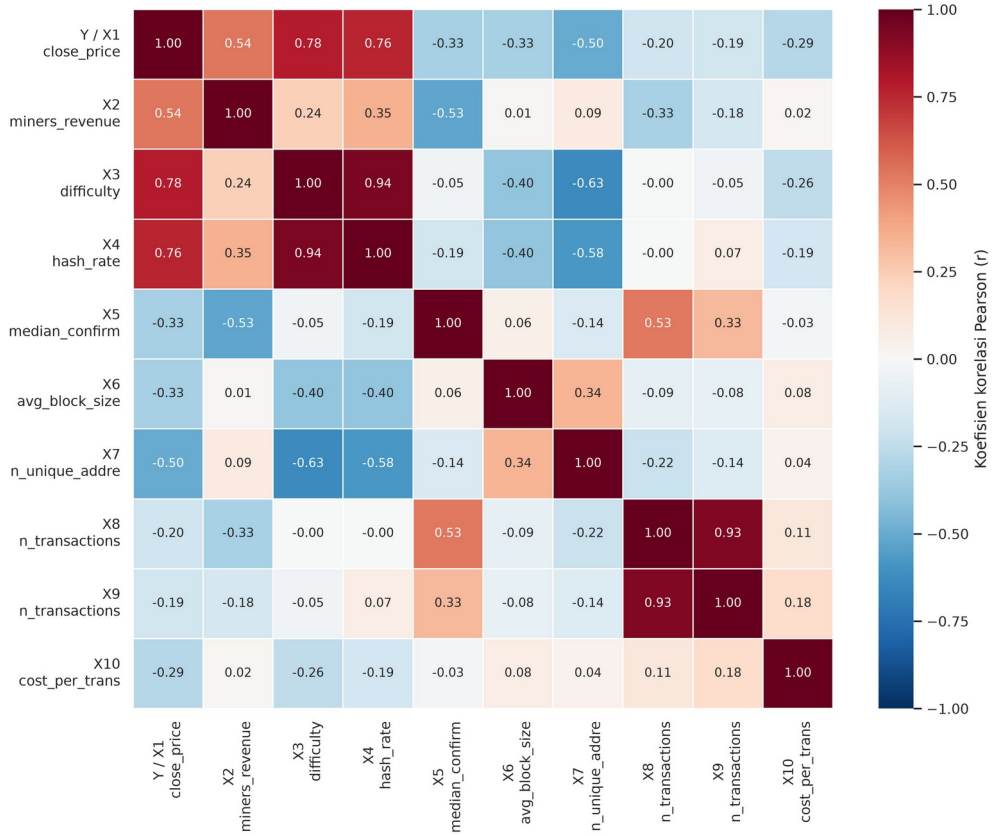
Berdasarkan Gambar 9, harga penutupan Bitcoin bergerak dari kisaran 30.000 USD pada pertengahan 2023, naik hingga sekitar 70.000 USD pada awal 2024, bergerak mendatar hingga akhir 2024, lalu menembus 100.000 USD dan

mencapai puncaknya pada Oktober 2025. Setelah itu harga terkoreksi tajam hingga berada di kisaran 60.000 sampai 65.000 USD pada pertengahan 2026. Variabel *Difficulty* dan *Hash Rate* menunjukkan tren naik yang konsisten dan searah dengan harga hingga akhir 2025, yang menandakan jaringan semakin aman dan kompetitif seiring kenaikan nilai asetnya. *Difficulty* tampak berbentuk anak tangga karena disesuaikan setiap 2.016 blok.

Miners Revenue dan *Cost % per Transaction* memperlihatkan lonjakan ekstrem sekitar April 2024 yang bertepatan dengan peristiwa *halving* keempat Bitcoin, yaitu ketika imbalan blok dipotong setengahnya sehingga pendapatan penambang turun tajam setelahnya. Variabel aktivitas jaringan seperti *Confirmed Transaction*, *Transaction per Block*, dan *Average Block Size* lebih fluktuatif dan tidak memiliki tren jangka panjang yang searah dengan harga, sedangkan *Total Unique Addresses* cenderung menurun sejak awal 2024. Pola ini mengindikasikan bahwa kenaikan harga lebih banyak didorong oleh investor yang sudah ada daripada penambahan pengguna baru. Keeratan hubungan linier setiap variabel terhadap harga penutupan disajikan pada Tabel 10 dan Gambar 10.

Tabel 10. Korelasi Pearson Variabel *Blockchain* terhadap Harga Penutupan

Kode	Variabel	r	Interpretasi Korelasi
X_3	*Difficulty*	0,7827	Cukup kuat dan positif (searah)
X_4	*Hash Rate*	0,7629	Cukup kuat dan positif (searah)
X_2	*Miners Revenue*	0,5385	Sedang dan positif (searah)
X_9	*Confirmed Transaction*	-0,1921	Sangat rendah dan negatif (berlawanan arah)
X_8	*Transaction per Block*	-0,1962	Sangat rendah dan negatif (berlawanan arah)
X_{10}	*Cost % per Transaction*	-0,2888	Rendah dan negatif (berlawanan arah)
X_6	*Average Block Size*	-0,3312	Rendah dan negatif (berlawanan arah)
X_5	*Median Confirmation Time*	-0,3338	Rendah dan negatif (berlawanan arah)
X_7	*Total Unique Addresses*	-0,5025	Sedang dan negatif (berlawanan arah)



Gambar 10. *Heatmap* Korelasi Pearson Antarvariabel

Difficulty ($r = 0{,}7827$) dan *Hash Rate* ($r = 0{,}7629$) memiliki korelasi kuat dan positif terhadap harga penutupan, *Miners Revenue* ($r = 0{,}5385$) berkorelasi sedang dan positif, sedangkan *Total Unique Addresses* ($r = -0{,}5025$) berkorelasi sedang dan negatif. Variabel lainnya hanya berkorelasi lemah. Korelasi linier yang lemah tidak berarti variabel tersebut tidak berguna, karena LSTM dan GRU mampu menangkap hubungan nonlinier dan hubungan yang bergantung pada urutan waktu. Gambar 10 juga menunjukkan korelasi yang sangat kuat antara *Difficulty* dan *Hash Rate* karena tingkat kesulitan disesuaikan mengikuti daya komputasi jaringan.

3.2 Data *Preprocessing*

3.2.1 Pemeriksaan dan Penanganan *Missing Value*

Langkah pertama *preprocessing* adalah memeriksa *missing value*, tanggal yang hilang dari kalender harian, dan tanggal duplikat. Hasil pemeriksaan disajikan pada Tabel 11.

Tabel 11. Pemeriksaan *Missing Value* pada Setiap Variabel

Kode	Variabel	Jumlah Kosong	Persentase (%)
Y / X_1	*Close Price*	0	0,0000
X_2	*Miners Revenue*	0	0,0000
X_3	*Difficulty*	3	0,2662
X_4	*Hash Rate*	3	0,2662
X_5	*Median Confirmation Time*	3	0,2662
X_6	*Average Block Size*	3	0,2662
X_7	*Total Unique Addresses*	4	0,3549
X_8	*Transaction per Block*	3	0,2662
X_9	*Confirmed Transaction*	3	0,2662
X_{10}	*Cost % per Transaction*	5	0,4437
	Total	**27**	**0,2396**

Terdapat 27 sel kosong atau 0,2396% dari seluruh 11.270 sel yang tersebar pada sembilan tanggal, sedangkan tanggal yang hilang dan tanggal duplikat tidak ditemukan. Tanggal-tanggal yang memiliki nilai kosong disajikan pada Tabel 12.

Tabel 12. Tanggal yang Memiliki *Missing Value*

Tanggal	Variabel yang Kosong
14/07/2023	X_{10}
14/11/2023	X_{10}
30/06/2024	X_{10}
18/11/2024	X_{10}
24/06/2025	X_{10}
13/11/2025	X_3, X_4, X_5, X_6, X_7, X_8, X_9
14/11/2025	X_3, X_4, X_5, X_6, X_7, X_8, X_9
15/11/2025	X_3, X_4, X_5, X_6, X_7, X_8, X_9
16/04/2026	X_7

Karena baris tidak dapat dihapus tanpa memutus keteraturan runtun waktu harian, seluruh nilai kosong ditangani dengan *forward fill* sesuai persamaan (4). Sebagai contoh, *Cost % per Transaction* (X_{10}) pada tanggal 14 Juli 2023 kosong sehingga diisi dengan nilai hari sebelumnya:

$$x_{10,14/07/2023} = x_{10,13/07/2023} = 0{,}428204$$

Dengan cara yang sama, tujuh variabel yang kosong pada tanggal 13 sampai 15 November 2025 diisi dengan nilai tanggal 12 November 2025, misalnya *Difficulty* sebesar 155.027.936.004.971,75. Setelah penanganan, tidak terdapat lagi nilai kosong sehingga diperoleh 1.127 baris data harian yang lengkap dan berurutan.

3.2.2 Pembagian Data

Data dibagi secara kronologis sebelum normalisasi dilakukan. Dengan $n = 1.127$, ukuran setiap bagian dihitung menggunakan persamaan (5):

$$n_{\text{lp}} = \lfloor 0{,}8 \times 1.127 \rfloor = \lfloor 901{,}6 \rfloor = 901 \; n_{\text{uji}} = 1.127 - 901 = 226$$
$$n_{\text{val}} = \lfloor 0{,}1 \times 901 \rfloor = \lfloor 90{,}1 \rfloor = 90 \; n_{\text{latih}} = 901 - 90 = 811$$

Tabel 13. Pembagian Data

Bagian	Periode	Jumlah	Persentase (%)	Harga Terendah (USD)	Harga Tertinggi (USD)
Data latih	01/07/2023 – 18/09/2025	811	71,96	25.162,70	123.359,45
Data validasi	19/09/2025 – 17/12/2025	90	7,99	84.677,63	124.776,68
Data uji	18/12/2025 – 31/07/2026	226	20,05	58.534,28	96.931,94
Total	01/07/2023 – 31/07/2026	1.127	100,00	25.162,70	124.776,68

Data latih mencakup 811 hari (1 Juli 2023 s.d. 18 September 2025), data validasi 90 hari (19 September 2025 s.d. 17 Desember 2025), dan data uji 226 hari (18 Desember 2025 s.d. 31 Juli 2026). Pembagian dilakukan tanpa pengacakan karena data runtun waktu tidak dapat diacak. Data validasi hanya digunakan untuk memilih *hyperparameter*, sedangkan data uji disimpan utuh sebagai penilai akhir yang netral. Harga tertinggi sepanjang periode (124.776,68 USD) berada pada data validasi, sedangkan seluruh harga pada data uji (58.534,28 sampai 96.931,94 USD) masih berada di dalam rentang harga data latih.

3.2.3 Normalisasi Data

Normalisasi *min-max* dilakukan dengan nilai minimum dan maksimum yang hanya dihitung dari data latih, kemudian nilai yang sama digunakan untuk mentransformasi data validasi dan data uji. Nilai minimum dan maksimum setiap variabel disajikan pada Tabel 14.

Tabel 14. Nilai Minimum dan Maksimum Tiap Variabel pada Data Latih

Kode	Variabel (Satuan)	$x_{\min}$	$x_{\max}$	$x_{\max} - x_{\min}$
Y / X_1	*Close Price* (USD)	25.162,70	123.359,45	98.196,75
X_2	*Miners Revenue* (juta USD)	19,27	107,76	88,48
X_3	*Difficulty* ($\times 10^{12}$)	50,65	138,47	87,83
X_4	*Hash Rate* (juta TH/s)	300,15	1.149,64	849,49
X_5	*Median Confirmation Time* (menit)	0,058	18,042	17,983
X_6	*Average Block Size* (MB)	1,065	2,293	1,228
X_7	*Total Unique Addresses* (ribu alamat)	358,4	1.017,5	659,1
X_8	*Transaction per Block* (transaksi/blok)	1.430,216	5.517,917	4.087,700
X_9	*Confirmed Transaction* (ribu transaksi)	242,4	927,0	684,6
X_{10}	*Cost % per Transaction* (%)	0,119	5,826	5,707

Berikut contoh perhitungan *min-max scaling* menggunakan persamaan (6) pada atribut *Close Price* tanggal 1 Juli 2023 yang bernilai 30.471,50 USD, dengan nilai terendah dan tertinggi data latih sebesar 25.162,70 dan 123.359,45:

$$x'_{1,01/07/2023} = \frac{30.471{,}50 - 25.162{,}70}{123.359{,}45 - 25.162{,}70} = \frac{5.308{,}80}{98.196{,}75} = 0{,}054063$$

Hasil tersebut sama dengan keluaran MinMaxScaler dengan selisih absolut hanya $1{,}39 \times 10^{-17}$. Uji balik melalui persamaan (8) juga mengembalikan nilai aslinya, yaitu $0{,}054063 \times 98.196{,}75 + 25.162{,}70 = 30.471{,}50$ USD. Karena penskala hanya mengenal rentang data latih, nilai ternormalisasi pada data validasi berada pada rentang $[-0{,}009212\,;\,1{,}199253]$ dan pada data uji $[0{,}002698\,;\,1{,}111415]$. Pada data uji, *Difficulty* bernilai lebih dari 1 selama 108 hari dan *Hash Rate* selama 9 hari, sedangkan *Close Price* tetap berada pada rentang $[0{,}339844\,;\,0{,}730872]$ sehingga model tidak perlu mengekstrapolasi harga di luar rentang data latih.

3.2.4 Pembentukan *Sliding Window*

Setelah dinormalisasi, data diubah menjadi pasangan masukan dan target sesuai persamaan (7) dengan panjang *window* tujuh hari. Jendela untuk hari pertama data validasi dan data uji menggunakan tujuh hari sebelumnya sebagai konteks historis sehingga tidak ada hari yang terbuang dan tidak terjadi kebocoran data. Bentuk data yang dihasilkan adalah $\mathbf{X}_{\text{latih}} \in \mathrm{R}^{804 \times 7 \times 10}$, $\mathbf{X}_{\text{val}} \in \mathrm{R}^{90 \times 7 \times 10}$, dan $\mathbf{X}_{\text{uji}} \in \mathrm{R}^{226 \times 7 \times 10}$. Jendela pertama data latih, yang sekaligus merupakan hasil normalisasi tujuh hari pertama, disajikan pada Tabel 15.

Tabel 15. Jendela Pertama Data Latih (Nilai Ternormalisasi)

Hari	Tanggal	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	X_9	X_{10}
$t-6$	01/07/2023	0,054063	0,077789	0,000000	0,040839	0,513902	0,481952	0,400071	0,246577	0,119541	0,125072
$t-5$	02/07/2023	0,055285	0,163910	0,000000	0,153461	0,383225	0,612254	0,266889	0,093495	0,098573	0,283276
$t-4$	03/07/2023	0,055557	0,098530	0,000000	0,052694	0,699259	0,582513	0,450626	0,236019	0,125150	0,117043
$t-3$	04/07/2023	0,060982	0,105879	0,000000	0,067513	0,625579	0,537856	0,435673	0,302290	0,198834	0,141810
$t-2$	05/07/2023	0,057152	0,124744	0,000000	0,106041	0,507414	0,511676	0,543396	0,428973	0,366709	0,153320
$t-1$	06/07/2023	0,054379	0,088756	0,000000	0,058622	0,528730	0,478138	0,531970	0,341238	0,219478	0,074135
t	07/07/2023	0,048427	0,166597	0,000000	0,165316	0,427711	0,598191	0,629480	0,427381	0,458060	0,172204

Target jendela ini adalah *Close Price* tanggal 08/07/2023, yaitu $y = 0{,}052770$ atau 30.344,53 USD. *Difficulty* (X_3) bernilai 0 karena tanggal 1–7 Juli 2023 memuat nilai *difficulty* terendah pada data latih.

3.3 Pengelolaan Model LSTM

Setelah data siap, langkah selanjutnya adalah menentukan inisialisasi parameter LSTM, yaitu jumlah *neuron* pada lapisan tersembunyi dan jumlah *epoch* pelatihan. Tidak ada aturan baku yang menentukan banyaknya *neuron*. Jaringan dengan *neuron* yang terlalu sedikit tidak mampu menangkap hubungan kompleks antara variabel target dan masukan, sedangkan *neuron* yang terlalu banyak dapat menyebabkan *overparameterization* sehingga kemampuan prediksi pada data yang belum pernah dilihat menjadi buruk. Demikian pula *epoch* yang terlalu sedikit membuat jaringan belum mengenali pola, sedangkan *epoch* yang terlalu banyak dapat menyebabkan *overfitting*. Oleh karena itu, dilakukan percobaan terhadap jumlah *neuron* 10, 20, 30, 40, dan 50 serta jumlah *epoch* 100, 500, dan 1000 dengan pengaturan lain sesuai Tabel 6.

3.3.1 Penentuan Jumlah *Neuron* dan *Epoch*

Kelima belas kombinasi dilatih pada data latih dan dinilai menggunakan RMSE pada data validasi, bukan data uji, agar data uji tetap netral. Hasil pengujian disajikan pada Tabel 16.

Tabel 16. Hasil Pengujian *Neuron* dan *Epoch* Model LSTM

No.	*Neuron*	*Epoch*	RMSE Validasi (USD)	MAPE Validasi (%)	Waktu Latih (detik)	Jumlah Parameter
1	10	100	8.259,72	7,3946	15,46	851
2	10	500	5.469,15	4,8198	71,78	851
3	10	1.000	3.414,57	2,7872	144,31	851
4	20	100	3.609,18	2,7862	17,01	2.501
5	20	500	3.465,39	2,8505	75,61	2.501
6	20	1.000	2.822,35	2,2753	148,92	2.501
7	30	100	4.224,85	3,4181	15,71	4.951
8	30	500	3.369,81	2,7565	75,13	4.951
9	30	1.000	2.918,21	2,3673	149,10	4.951
10	40	100	3.804,03	3,0128	16,14	8.201
11	**40**	**500**	**2.503,99**	**1,9025**	**79,56**	**8.201**
12	40	1.000	2.718,20	2,1301	154,19	8.201
13	50	100	5.737,57	4,9721	17,72	12.251
14	50	500	4.270,99	3,6347	81,19	12.251
15	50	1.000	3.546,03	2,7296	155,37	12.251

Baris bercetak tebal merupakan konfigurasi dengan RMSE validasi terkecil.

Berdasarkan Tabel 16, kombinasi 40 *neuron* dan 500 *epoch* menghasilkan RMSE validasi terkecil, yaitu 2.503,99 USD dengan MAPE validasi 1,9025%. Konfigurasi dengan *neuron* dan *epoch* paling sedikit (10 *neuron*, 100 *epoch*) menghasilkan RMSE tertinggi sebesar 8.259,72 USD karena jaringan belum cukup belajar (*underfitting*). Penambahan *epoch* tidak selalu memperbaiki hasil: pada 40 *neuron*, RMSE validasi naik dari 2.503,99 USD (500 *epoch*) menjadi 2.718,20 USD (1000 *epoch*), yang mengindikasikan awal terjadinya *overfitting*. Waktu latih bertambah hampir sebanding dengan jumlah *epoch*, yaitu sekitar 0,14 sampai 0,18 detik per *epoch*.

3.3.2 Arsitektur dan Jumlah Parameter Model LSTM

Model LSTM terbaik terdiri atas lapisan masukan berbentuk (7, 10), satu lapisan LSTM dengan 40 *neuron*, dan satu lapisan *dense* dengan satu keluaran. Ringkasan arsitektur model disajikan pada Tabel 17.

Tabel 17. Arsitektur Model LSTM Terbaik

Lapisan (Tipe)	Bentuk Keluaran	Jumlah Parameter
Masukan (*Input*)	(*None*, 7, 10)	0
Lapisan rekuren (LSTM)	(*None*, 40)	8.160
Lapisan keluaran (*Dense*)	(*None*, 1)	41
Total parameter terlatih		**8.201**

Jumlah parameter tersebut dapat diverifikasi secara manual menggunakan persamaan (22) dengan $n_u = 40$ dan $n_f = 10$:

$$P_{\text{LSTM}} = 4\left[40(40+10)+40\right]+(40+1)$$
$$= 4\left[2.000+40\right]+41 = 4 \times 2.040+41 = 8.160+41 = 8.201$$

Setiap himpunan gerbang memiliki $40 \times 10 = 400$ bobot masukan, $40 \times 40 = 1.600$ bobot rekuren, dan 40 bias, sehingga satu gerbang memiliki 2.040 parameter. Keras menyimpan keempat gerbang dalam satu matriks gabungan dengan urutan i, f, c, o seperti pada Tabel 18.

Tabel 18. Rincian Bobot Model LSTM Terbaik

Bobot	Peran	Bentuk	Jumlah Elemen
kernel $\mathbf{W}$	masukan $\mathbf{x}_t$ -> 4 gerbang	(10, 160)	1.600
recurrent kernel $\mathbf{U}$	$\mathbf{h}_{t-1}$ -> 4 gerbang	(40, 160)	6.400
bias $\mathbf{b}$	bias 4 gerbang	(160,)	160
Dense kernel $\mathbf{W}_y$	$\mathbf{h}_T$ -> keluaran	(40, 1)	40
Dense bias b_y	bias keluaran	(1,)	1
Total			8.201

3.3.3 Perhitungan Secara Manual Model LSTM

Berikut ini adalah contoh perhitungan LSTM pada jendela pertama data uji, yaitu data tanggal 11 sampai 17 Desember 2025 yang digunakan untuk memprediksi harga penutupan 18 Desember 2025 (harga aktual 86.132,82 USD). Perhitungan menggunakan bobot hasil pelatihan model terbaik (40 *neuron*, 500 *epoch*) dan dicontohkan pada *neuron* ke-1. Keadaan awal adalah $\mathbf{h}_0 = \mathbf{0}$ dan $\mathbf{c}_0 = \mathbf{0}$. Nilai masukan pada *time step* pertama ($t = 1$, 11 Desember 2025) beserta bobot masukan dan bias *neuron* ke-1 untuk setiap gerbang disajikan pada Tabel 19.

Tabel 19. Nilai *Input*, *Weight*, dan Bias *Neuron* ke-1 Model LSTM

Variabel	$\mathbf{x}_1$	$\mathbf{W}_i[:,1]$	$\mathbf{W}_f[:,1]$	$\mathbf{W}_c[:,1]$	$\mathbf{W}_o[:,1]$
X_1 *Close Price*	0,680495	0,413355	-0,066825	0,158535	0,321498
X_2 *Miners Revenue*	0,297207	-0,016684	0,108273	0,309700	-0,126170
X_3 *Difficulty*	1,112427	0,125940	0,047586	-0,162692	0,379633
X_4 *Hash Rate*	1,035626	-0,200919	-0,092290	-0,077519	-0,219034
X_5 *Median Conf. Time*	0,507183	-0,059908	-0,222868	0,197350	-0,206085
X_6 *Avg. Block Size*	0,393311	-0,082207	-0,322515	0,000810	-0,152426
X_7 *Unique Addresses*	0,235063	-0,518425	-0,626940	0,068815	-0,604805
X_8 *Tx per Block*	0,373105	-0,265667	-0,091566	-0,092497	-0,106231
X_9 *Confirmed Tx*	0,336586	-0,408494	-0,190472	0,074651	-0,281759
X_{10} *Cost % per Tx*	0,053572	-0,317435	-0,258931	0,007119	-1,053337
Bias $b[1]$		-0,342494	0,681141	-0,011402	-0,373906

Nilai X_3 dan X_4 lebih dari 1 karena *Difficulty* dan *Hash Rate* pada periode uji melampaui nilai tertinggi data latih. Bias *forget gate* bernilai positif karena Keras menginisialisasinya dengan 1 (*unit forget bias*).

a. *Time Step* ke-1 ($t=1$)

Forget gate menentukan informasi yang dihilangkan dari *cell state*. Karena $\mathbf{h}_0=\mathbf{0}$, suku rekuren bernilai nol. Kontribusi masukan dihitung sebagai perkalian titik antara $\mathbf{x}_1$ dan kolom pertama $\mathbf{W}_f$, kemudian dijumlahkan dengan bias dan dimasukkan ke fungsi sigmoid menggunakan persamaan (15):

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_f[:,1] &= (0{,}680495)(-0{,}066825)+(0{,}297207)(0{,}108273)+(1{,}112427)(0{,}047586)\\ &+(1{,}035626)(-0{,}092290)+(0{,}507183)(-0{,}222868)+(0{,}393311)(-0{,}322515)\\ &+(0{,}235063)(-0{,}626940)+(0{,}373105)(-0{,}091566)+(0{,}336586)(-0{,}190472)\\ &+(0{,}053572)(-0{,}258931)\\ &=-0{,}045474+0{,}032179+0{,}052936-0{,}095578-0{,}113035\\ &-0{,}126849-0{,}147370-0{,}034164-0{,}064110-0{,}013871\\ &=-0{,}555336\end{aligned}$$

$$z_f=\mathbf{x}_1\mathbf{W}_f[:,1]+\mathbf{h}_0\mathbf{U}_f[:,1]+b_f[1]=-0{,}555336+0+0{,}681141\approx 0{,}125804$$

$$f_1[1]=\sigma(0{,}125804)=\frac{1}{1+e^{-0{,}125804}}=\frac{1}{1+0{,}881788}=0{,}531410$$

Nilai 0,531410 berarti sekitar 53% memori lama dipertahankan. Selanjutnya *input gate* dihitung dengan persamaan (16):

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_i[:,1] &= (0{,}680495)(0{,}413355)+(0{,}297207)(-0{,}016684)+(1{,}112427)(0{,}125940)\\ &+(1{,}035626)(-0{,}200919)+(0{,}507183)(-0{,}059908)+(0{,}393311)(-0{,}082207)\\ &+(0{,}235063)(-0{,}518425)+(0{,}373105)(-0{,}265667)+(0{,}336586)(-0{,}408494)\\ &+(0{,}053572)(-0{,}317435)\\ &= 0{,}281286-0{,}004959+0{,}140099-0{,}208077-0{,}030384\\ &-0{,}032333-0{,}121863-0{,}099122-0{,}137493-0{,}017006\\ &= -0{,}229851\end{aligned}$$

$$z_i = -0{,}229851+0-0{,}342494 = -0{,}572345$$

$$i_1[1] = \sigma(-0{,}572345) = \frac{1}{1+e^{0{,}572345}} = \frac{1}{1+1{,}772419} = 0{,}360696$$

Kandidat *cell state* dihitung menggunakan persamaan (17), dengan fungsi tanh yang dihubungkan dengan fungsi sigmoid melalui persamaan (13):

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_c[:,1] &= (0{,}680495)(0{,}158535)+(0{,}297207)(0{,}309700)+(1{,}112427)(-0{,}162692)\\ &+(1{,}035626)(-0{,}077519)+(0{,}507183)(0{,}197350)+(0{,}393311)(0{,}000810)\\ &+(0{,}235063)(0{,}068815)+(0{,}373105)(-0{,}092497)+(0{,}336586)(0{,}074651)\\ &+(0{,}053572)(0{,}007119)\\ &= 0{,}107882+0{,}092045-0{,}180983-0{,}080281+0{,}100093\\ &+0{,}000319+0{,}016176-0{,}034511+0{,}025126+0{,}000381\\ &= 0{,}046247\end{aligned}$$

$$z_c = 0{,}046247+0-0{,}011402 \approx 0{,}034844$$

$$\tilde{c}_1[1] = \tanh(0{,}034844) = 2\sigma(2\times 0{,}034844)-1 = \frac{2}{1+e^{-0{,}069688}}-1 = \frac{2}{1+0{,}932685}-1 = 0{,}034830$$

Output gate dihitung menggunakan persamaan (19):

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_o[:,1] &= (0{,}680495)(0{,}321498)+(0{,}297207)(-0{,}126170)+(1{,}112427)(0{,}379633)\\ &+(1{,}035626)(-0{,}219034)+(0{,}507183)(-0{,}206085)+(0{,}393311)(-0{,}152426)\\ &+(0{,}235063)(-0{,}604805)+(0{,}373105)(-0{,}106231)+(0{,}336586)(-0{,}281759)\\ &+(0{,}053572)(-1{,}053337)\\ &= 0{,}218778-0{,}037499+0{,}422314-0{,}226837-0{,}104523\\ &-0{,}059951-0{,}142167-0{,}039635-0{,}094836-0{,}056429\\ &= -0{,}120786\end{aligned}$$

$$z_o = -0{,}120786+0-0{,}373906 = -0{,}494692$$

$$o_1[1] = \sigma(-0{,}494692) = \frac{1}{1+e^{0{,}494692}} = \frac{1}{1+1{,}639993} = 0{,}378789$$

Setelah keempat gerbang diperoleh, *cell state* dan *hidden state time step* pertama dihitung menggunakan persamaan (18) dan (20):

$$c_1[1] = f_1[1]\times c_0[1]+i_1[1]\times\tilde{c}_1[1] = 0{,}531410\times 0+0{,}360696\times 0{,}034830 = 0{,}012563$$

$$h_1[1] = o_1[1]\times\tanh(c_1[1]) = 0{,}378789\times\tanh(0{,}012563) = 0{,}378789\times 0{,}012563 = 0{,}004759$$

Perhitungan yang sama dilakukan untuk 39 *neuron* lainnya sehingga diperoleh vektor *hidden state* dan *cell state* yang masing-masing berisi 40 elemen:

$$\mathbf{h}_1 = [0{,}004759\,;\, 0{,}095690\,;\, -0{,}065626\,;\, 0{,}036352\,;\, 0{,}071958\,;\, 0{,}002893\,;\, \ldots]$$

$$\mathbf{c}_1 = [0{,}012563\,;\, 0{,}154995\,;\, -0{,}133021\,;\, \ldots]$$

b. *Time Step* ke-2 ($t = 2$)

Pada *time step* kedua (12 Desember 2025), $\mathbf{h}_1$ tidak lagi bernilai nol sehingga suku rekuren $\mathbf{h}_1 \mathbf{U}[:, 1]$ merupakan penjumlahan 40 perkalian. Misalnya untuk *input gate*:

$$\mathbf{h}_1 \mathbf{U}_i[:, 1] = (0{,}004759)(-0{,}209807) + (0{,}095690)(0{,}034556) + (-0{,}065626)(-0{,}026079) + (0{,}036352)(0{,}043449) + (0{,}071958)(0{,}147345) + (0{,}002893)(-0{,}091875) + \cdots = 0{,}200970$$

Dengan cara yang sama, seluruh gerbang pada *time step* kedua untuk *neuron* ke-1 diperoleh sebagai berikut:

$$i_2[1] = \sigma(-0{,}181728 + 0{,}200970 - 0{,}342494) = \sigma(-0{,}323251) = 0{,}419884$$
$$f_2[1] = \sigma(-0{,}549561 + 0{,}035781 + 0{,}681141) = \sigma(0{,}167360) = 0{,}541743$$
$$\tilde{c}_2[1] = \tanh(0{,}042649 - 0{,}094830 - 0{,}011402) = \tanh(-0{,}063584) = -0{,}063499$$
$$o_2[1] = \sigma(-0{,}080591 + 0{,}217060 - 0{,}373906) = \sigma(-0{,}237437) = 0{,}440918$$
$$c_2[1] = 0{,}541743 \times 0{,}012563 + 0{,}419884 \times (-0{,}063499) = 0{,}006806 - 0{,}026662 = -0{,}019856$$
$$h_2[1] = 0{,}440918 \times \tanh(-0{,}019856) = 0{,}440918 \times (-0{,}019853) = -0{,}008754$$

Langkah perhitungan tersebut dilakukan pada setiap *time step* hingga $t = 7$. Nilai $\mathbf{c}_t$ dan $\mathbf{h}_t$ dibawa ke *time step* berikutnya. Ringkasan nilai setiap gerbang untuk *neuron* ke-1 disajikan pada Tabel 20.

Tabel 20. Ringkasan Perhitungan LSTM *Neuron* ke-1 pada Setiap *Time Step*

t	**Tanggal**	$i_t[1]$	$f_t[1]$	$\tilde{c}_t[1]$	$o_t[1]$	$c_t[1]$	$h_t[1]$
1	11/12/2025	0,360696	0,531410	0,034830	0,378789	0,012563	0,004759
2	12/12/2025	0,419884	0,541743	-0,063499	0,440918	-0,019856	-0,008754
3	13/12/2025	0,417889	0,555581	-0,103225	0,437682	-0,054168	-0,023685
4	14/12/2025	0,442823	0,577537	-0,116985	0,458542	-0,083088	-0,038012
5	15/12/2025	0,431293	0,561556	-0,113300	0,477979	-0,095524	-0,045520
6	16/12/2025	0,425508	0,568267	-0,141336	0,477070	-0,114423	-0,054351
7	17/12/2025	0,426827	0,561746	-0,141349	0,478256	-0,124608	-0,059288

c. Lapisan *Dense*

Hidden state pada *time step* terakhir diubah menjadi nilai prediksi menggunakan persamaan (21). Nilai $\mathbf{h}_7$, bobot $\mathbf{W}_y$, dan bias lapisan *dense* adalah sebagai berikut:

$$\mathbf{h}_7 = [-0{,}059288\,;\,0{,}033720\,;\,-0{,}036911\,;\,0{,}038392\,;\,0{,}102880\,;\,0{,}008137\,;\,\ldots]$$

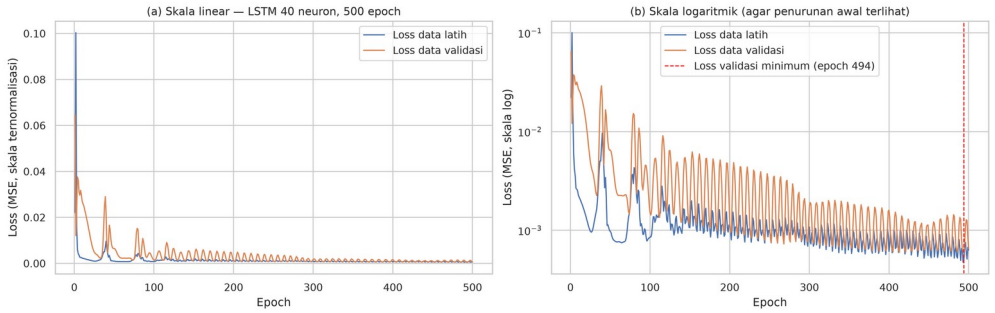
$$\mathbf{W}_y = [0{,}164646\,;\,0{,}297487\,;\,-0{,}051887\,;\,0{,}160470\,;\,0{,}265961\,;\,0{,}041397\,;\,\ldots],\, b_y = 0{,}081419$$

$$\begin{aligned}\hat{y}' = {} & (-0{,}059288)(0{,}164646) + (0{,}033720)(0{,}297487) + (-0{,}036911)(-0{,}051887) \\ & + (0{,}038392)(0{,}160470) + (0{,}102880)(0{,}265961) + (0{,}008137)(0{,}041397) \\ & + \cdots + h_7[40]\,W_y[40] + 0{,}081419 \\ = {} & -0{,}009762 + 0{,}010031 + 0{,}001915 + 0{,}006161 + 0{,}027362 + 0{,}000337 + \cdots + 0{,}081419 \\ = {} & 0{,}560887 + 0{,}081419 = 0{,}642306\end{aligned}$$

Hasil perhitungan manual sebesar 0,6423063572 identik dengan keluaran model.predict() Keras, yaitu 0,6423063278, dengan selisih absolut hanya $2{,}94 \times 10^{-8}$. Dengan demikian, persamaan (15) sampai (21) terbukti merupakan rumus yang dijalankan oleh Keras. Nilai prediksi ternormalisasi ini dikembalikan ke skala USD pada Subbab 3.6.

3.3.4 Kurva *Loss* Model LSTM

Proses pelatihan model LSTM terbaik ditunjukkan oleh kurva *loss* data latih dan data validasi pada Gambar 11.



Gambar 11. Kurva *Loss* Data Latih dan Validasi Model LSTM Terbaik

Loss data latih turun dari 0,02209279 pada *epoch* pertama menjadi 0,00063068 pada *epoch* ke-500 atau berkurang 97,15%, sedangkan *loss* validasi turun dari 0,06462061 menjadi 0,00065024 dengan nilai minimum 0,00059231 pada *epoch* ke-494. Kedua kurva menurun bersama tanpa jarak yang melebar, sehingga model tidak menunjukkan tanda *overfitting* yang berarti pada konfigurasi terpilih.

3.4 Pengelolaan Model GRU

Model GRU dibangun dan dilatih menggunakan fungsi yang sama persis dengan LSTM, yaitu dengan data, *window*, *grid neuron* dan *epoch*, *batch size*, *optimizer*, *learning rate*, dan *seed* yang identik. Satu-satunya perbedaan adalah jenis lapisan rekuren yang digunakan.

3.4.1 Penentuan Jumlah *Neuron* dan *Epoch*

Hasil pengujian kelima belas kombinasi jumlah *neuron* dan *epoch* model GRU disajikan pada Tabel 21.

Tabel 21. Hasil Pengujian *Neuron* dan *Epoch* Model GRU

No.	*Neuron*	*Epoch*	RMSE Validasi (USD)	MAPE Validasi (%)	Waktu Latih (detik)	Jumlah Parameter
1	10	100	8.899,66	7,9403	17,03	671
2	10	500	3.515,15	2,7970	79,07	671
3	10	1.000	2.643,55	2,0426	158,01	671
4	20	100	3.944,11	3,0962	17,84	1.941
5	20	500	2.709,45	2,0723	81,11	1.941
6	20	1.000	3.027,82	2,3324	161,08	1.941
7	30	100	4.157,69	3,2812	18,14	3.811
8	**30**	**500**	**2.564,89**	**1,9797**	**83,05**	**3.811**
9	30	1.000	4.602,29	3,9443	164,07	3.811
10	40	100	3.693,88	2,9362	18,55	6.281
11	40	500	3.000,19	2,3656	81,76	6.281
12	40	1.000	3.327,18	2,6279	164,71	6.281
13	50	100	7.911,04	7,1960	18,37	9.351
14	50	500	2.907,13	2,3094	86,45	9.351
15	50	1.000	2.680,68	2,0891	167,44	9.351

Baris bercetak tebal merupakan konfigurasi dengan RMSE validasi terkecil.

Berdasarkan Tabel 21, konfigurasi terbaik GRU adalah 30 *neuron* dan 500 *epoch* dengan RMSE validasi 2.564,89 USD dan MAPE validasi 1,9797%. Sama seperti LSTM, penambahan *epoch* tidak selalu memperbaiki hasil: pada 30 *neuron*, RMSE validasi memburuk dari 2.564,89 USD (500 *epoch*) menjadi 4.602,29 USD (1000 *epoch*). Menariknya, GRU dengan hanya 10 *neuron* dan 1000 *epoch* (671 parameter) sudah menghasilkan RMSE validasi 2.643,55 USD, mendekati konfigurasi terbaik.

3.4.2 Arsitektur dan Jumlah Parameter Model GRU

Tabel 22. Arsitektur Model GRU Terbaik

Lapisan (Tipe)	Bentuk Keluaran	Jumlah Parameter
Masukan (*Input*)	(*None*, 7, 10)	0
Lapisan rekuren (GRU)	(*None*, 30)	3.780
Lapisan keluaran (*Dense*)	(*None*, 1)	31
Total parameter terlatih		**3.811**

Jumlah parameter model GRU pada Tabel 22 diverifikasi menggunakan persamaan (27) dengan $n_u = 30$ dan $n_f = 10$:

$$P_{\text{GRU}} = 3\left[30(30+10)+2\times 30\right]+(30+1)$$
$$= 3\left[1.200+60\right]+31 = 3\times 1.260+31 = 3.780+31 = 3.811$$

Setiap himpunan bobot GRU memiliki 300 bobot masukan, 900 bobot rekuren, dan 60 bias (30 bias masukan dan 30 bias rekuren). Rincian bobot model GRU dengan urutan gerbang z, r, h disajikan pada Tabel 23.

Tabel 23. Rincian Bobot Model GRU Terbaik

Bobot	Peran	Bentuk	Jumlah Elemen
kernel $\mathbf{W}$	masukan $\mathbf{x}_t$ -> 3 gerbang	(10, 90)	900
recurrent kernel $\mathbf{U}$	$\mathbf{h}_{t-1}$ -> 3 gerbang	(30, 90)	2.700
bias $\mathbf{b}$	bias masukan + bias rekuren	(2, 90)	180
Dense kernel $\mathbf{W}_y$	$\mathbf{h}_T$ -> keluaran	(30, 1)	30
Dense bias b_y	bias keluaran	(1,)	1
Total			3.811

3.4.3 Perhitungan Secara Manual Model GRU

Perhitungan manual GRU menggunakan jendela pertama data uji yang sama dengan LSTM dan dicontohkan pada *neuron* ke-1. Keadaan awal adalah $\mathbf{h}_0 = \mathbf{0}$ karena GRU tidak memiliki *cell state*. Bobot masukan dan bias *neuron* ke-1 disajikan pada Tabel 24.

Tabel 24. Nilai *Input*, *Weight*, dan Bias *Neuron* ke-1 Model GRU

Variabel	$\mathbf{x}_1$	$\mathbf{W}_z[:,1]$	$\mathbf{W}_r[:,1]$	$\mathbf{W}_h[:,1]$
X_1 *Close Price*	0,680495	-0,004894	-0,466489	0,398500
X_2 *Miners Revenue*	0,297207	0,005574	-0,363806	-0,016380
X_3 *Difficulty*	1,112427	-0,035411	-0,198020	0,119456
X_4 *Hash Rate*	1,035626	-0,024312	-0,155058	0,269774
X_5 *Median Conf. Time*	0,507183	0,053985	-0,359717	-0,034389
X_6 *Avg. Block Size*	0,393311	-0,125109	-0,476919	-0,098092
X_7 *Unique Addresses*	0,235063	-0,004999	-0,418683	-0,104376
X_8 *Tx per Block*	0,373105	-0,387106	-0,101683	-0,147950
X_9 *Confirmed Tx*	0,336586	0,032508	-0,253078	-0,151735
X_{10} *Cost % per Tx*	0,053572	-0,225453	-0,349738	0,017280
Bias masukan $b^{[\text{in}]}[1]$		0,211800	-0,249689	0,000974
Bias rekuren $b^{[\text{rec}]}[1]$		0,211800	-0,249689	0,007737

Bias masukan dan bias rekuren gerbang z serta r bernilai sama karena keduanya

berawal dari nol dan menerima gradien yang identik selama pelatihan, sedangkan bias rekuren kandidat berbeda karena dikalikan dengan r_t.

a. *Time Step* ke-1 ($t=1$)

Update gate dihitung menggunakan persamaan (23). Karena $\mathbf{h}_0=\mathbf{0}$, suku rekuren bernilai nol:

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_z[:,1]&=(0{,}680495)(-0{,}004894)+(0{,}297207)(0{,}005574)+(1{,}112427)(-0{,}035411)\\&+(1{,}035626)(-0{,}024312)+(0{,}507183)(0{,}053985)+(0{,}393311)(-0{,}125109)\\&+(0{,}235063)(-0{,}004999)+(0{,}373105)(-0{,}387106)+(0{,}336586)(0{,}032508)\\&+(0{,}053572)(-0{,}225453)\\&=-0{,}003330+0{,}001657-0{,}039392-0{,}025178+0{,}027380\\&-0{,}049207-0{,}001175-0{,}144431+0{,}010942-0{,}012078\\&=-0{,}234813\end{aligned}$$

$$z_z=-0{,}234813+0+0{,}211800+0{,}211800=0{,}188787$$

$$z_1[1]=\sigma(0{,}188787)=\frac{1}{1+e^{-0{,}188787}}=\frac{1}{1+0{,}827963}=0{,}547057$$

Reset gate dihitung menggunakan persamaan (24):

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_r[:,1]&=(0{,}680495)(-0{,}466489)+(0{,}297207)(-0{,}363806)+(1{,}112427)(-0{,}198020)\\&+(1{,}035626)(-0{,}155058)+(0{,}507183)(-0{,}359717)+(0{,}393311)(-0{,}476919)\\&+(0{,}235063)(-0{,}418683)+(0{,}373105)(-0{,}101683)+(0{,}336586)(-0{,}253078)\\&+(0{,}053572)(-0{,}349738)\\&=-0{,}317443-0{,}108126-0{,}220283-0{,}160582-0{,}182442\\&-0{,}187577-0{,}098417-0{,}037938-0{,}085183-0{,}018736\\&=-1{,}416727\end{aligned}$$

$$z_r=-1{,}416727+0-0{,}249689-0{,}249689=-1{,}916105$$

$$r_1[1]=\sigma(-1{,}916105)=\frac{1}{1+e^{1{,}916105}}=\frac{1}{1+6{,}794443}=0{,}128297$$

Kandidat *hidden state* dihitung menggunakan persamaan (25). Jalur rekuren $\mathbf{h}_0\mathbf{U}_h[:,1]+b_h^{(\text{rec})}[1]$ bernilai $0+0{,}007737=0{,}007737$, kemudian dikalikan dengan *reset gate*:

$$\begin{aligned}\mathbf{x}_1\mathbf{W}_h[:,1]&=(0{,}680495)(0{,}398500)+(0{,}297207)(-0{,}016380)+(1{,}112427)(0{,}119456)\\&+(1{,}035626)(0{,}269774)+(0{,}507183)(-0{,}034389)+(0{,}393311)(-0{,}098092)\\&+(0{,}235063)(-0{,}104376)+(0{,}373105)(-0{,}147950)+(0{,}336586)(-0{,}151735)\\&+(0{,}053572)(0{,}017280)\\&=0{,}271177-0{,}004868+0{,}132886+0{,}279385-0{,}017442\\&-0{,}038581-0{,}024535-0{,}055201-0{,}051072+0{,}000926\\&=0{,}492676\end{aligned}$$

$$z_h=0{,}492676+0{,}000974+0{,}128297\times 0{,}007737\approx 0{,}494642$$

$$\tilde{h}_1[1]=\tanh(0{,}494642)=2\sigma(2\times 0{,}494642)-1=\frac{2}{1+e^{-0{,}989284}}-1=\frac{2}{1+0{,}371843}-1=0{,}457893$$

Hidden state time step pertama dihitung menggunakan persamaan (26):

$$h_1[1] = z_1[1] \times h_0[1] + (1 - z_1[1]) \times \tilde{h}_1[1] = 0{,}547057 \times 0 + 0{,}452943 \times 0{,}457893 = 0{,}207399$$

Perhitungan yang sama untuk 29 *neuron* lainnya menghasilkan vektor *hidden state* yang berisi 30 elemen:

$$\mathbf{h}_1 = [0{,}207399\,;\, 0{,}092430\,;\, -0{,}038048\,;\, 0{,}089672\,;\, 0{,}017425\,;\, 0{,}316330\,;\, \ldots]$$

b. *Time Step* ke-2 ($t = 2$)

Pada *time step* kedua, suku rekuren merupakan penjumlahan 30 perkalian. Seluruh komponen untuk *neuron* ke-1 diperoleh sebagai berikut:

$$z_2[1] = \sigma(-0{,}235080 - 0{,}148659 + 0{,}211800 + 0{,}211800) = \sigma(0{,}039861) = 0{,}509964$$
$$r_2[1] = \sigma(-1{,}387251 + 0{,}002460 - 0{,}249689 - 0{,}249689) = \sigma(-1{,}884169) = 0{,}131911$$
$$\text{jalur rekuren} = \mathbf{h}_1 \mathbf{U}_h[:, 1] + b_h^{(\text{rec})}[1] = -0{,}156035 + 0{,}007737 = -0{,}148298$$
$$\tilde{h}_2[1] = \tanh(0{,}468519 + 0{,}000974 + 0{,}131911 \times (-0{,}148298)) = \tanh(0{,}449931) = 0{,}421842$$
$$h_2[1] = 0{,}509964 \times 0{,}207399 + 0{,}490036 \times 0{,}421842 = 0{,}105766 + 0{,}206718 = 0{,}312484$$

Ringkasan perhitungan *neuron* ke-1 untuk ketujuh *time step* disajikan pada Tabel 25.

Tabel 25. Ringkasan Perhitungan GRU *Neuron* ke-1 pada Setiap *Time Step*

t	**Tanggal**	$z_t[1]$	$r_t[1]$	$\tilde{h}_t[1]$	$h_t[1]$
1	11/12/2025	0,547057	0,128297	0,457893	0,207399
2	12/12/2025	0,509964	0,131911	0,421842	0,312484
3	13/12/2025	0,498756	0,133666	0,383651	0,348156
4	14/12/2025	0,485916	0,150694	0,385784	0,367500
5	15/12/2025	0,485834	0,145139	0,372381	0,370009
6	16/12/2025	0,507048	0,144660	0,399035	0,384318
7	17/12/2025	0,506857	0,147030	0,376576	0,380500

c. Lapisan *Dense*

Nilai *hidden state* terakhir, bobot, dan bias lapisan *dense* model GRU adalah sebagai berikut:

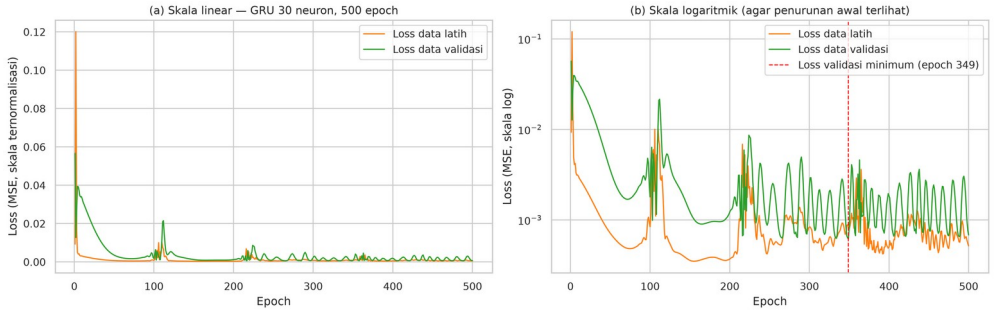
$$\mathbf{h}_7 = [0{,}380500\,;\, -0{,}016342\,;\, -0{,}094670\,;\, 0{,}198929\,;\, 0{,}035380\,;\, 0{,}332692\,;\, \ldots]$$

$$\mathbf{W}_y = [0{,}256136\,;\, 0{,}098238\,;\, -0{,}066118\,;\, 0{,}121973\,;\, 0{,}076804\,;\, 0{,}173387\,;\, \ldots],\ b_y = 0{,}042936$$

$$\hat{y}' = (0{,}380500)(0{,}256136) + (-0{,}016342)(0{,}098238) + (-0{,}094670)(-0{,}066118) + (0{,}198929)(0{,}121973) + (0{,}035380)(0{,}076804) + (0{,}332692)(0{,}173387) + \cdots + h_7[30]\,W_y[30] + 0{,}042936$$
$$= 0{,}097460 - 0{,}001605 + 0{,}006259 + 0{,}024264 + 0{,}002717 + 0{,}057685 + \cdots + 0{,}042936$$
$$= 0{,}604745 + 0{,}042936 = 0{,}647681$$

Hasil manual sebesar 0,6476814983 identik dengan keluaran model.predict() sebesar 0,6476814747 (selisih $2{,}37 \times 10^{-8}$). Sebagai pembanding, apabila digunakan rumus GRU asli Cho *et al*. (2014) pada bobot yang sama, diperoleh $\hat{y}' = 0{,}5364631926$ atau 77.841,64 USD, berbeda 0,111218 dari hasil Keras. Hal ini menegaskan bahwa perhitungan manual harus mengikuti konvensi Keras pada persamaan (23) sampai (26).

3.4.4 Kurva *Loss* Model GRU



Gambar 12. Kurva *Loss* Data Latih dan Validasi Model GRU Terbaik

Gambar 12 menunjukkan bahwa *loss* data latih GRU turun dari 0,00930230 menjadi 0,00051683 (berkurang 94,44%), sedangkan *loss* validasi turun dari 0,05659199 menjadi 0,00068225 dengan nilai minimum 0,00061486 pada *epoch* ke-349. Kurva *loss* turun mulus tanpa lonjakan sehingga proses pelatihan berlangsung stabil.

3.5 Perbandingan Arsitektur dan Uji Kestabilan

Perbandingan arsitektur dan efisiensi model LSTM dan GRU terbaik disajikan pada Tabel 26.

Tabel 26. Perbandingan Arsitektur Model LSTM dan GRU Terbaik

Aspek	LSTM	GRU
Konfigurasi terbaik	40 *neuron*, 500 *epoch*	30 *neuron*, 500 *epoch*
Jumlah gerbang	3 (*forget*, *input*, *output*)	2 (*update*, *reset*)
Memori internal	$\mathbf{h}_t$ dan $\mathbf{c}_t$	Hanya $\mathbf{h}_t$
Jumlah parameter lapisan rekuren	8.160	3.780
Jumlah parameter total	8.201	3.811
Waktu latih total (detik)	79,56	83,05
Waktu latih per *epoch* (detik)	0,1591	0,1661
RMSE data validasi (USD)	2.503,99	2.564,89
MAPE data validasi (%)	1,9025	1,9797

GRU terbaik hanya memakai 3.811 parameter atau 46,47% dari jumlah parameter LSTM terbaik (8.201). Namun, waktu latih GRU justru sedikit lebih lama (0,1661 berbanding 0,1591 detik per *epoch*, atau 4,38% lebih lambat). Hal ini terjadi karena model berukuran kecil dijalankan pada CPU sehingga waktu komputasi lebih banyak dipengaruhi oleh jumlah operasi berurutan per *time step* daripada jumlah parameter. Agar pengaruh arsitektur terlihat murni, jumlah parameter keduanya pada jumlah *neuron* yang sama disajikan pada Tabel 27.

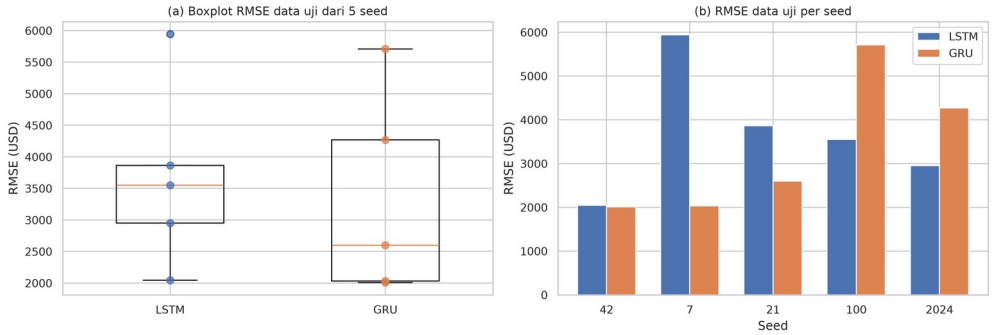
Tabel 27. Perbandingan Jumlah Parameter pada Jumlah *Neuron* yang Sama

Neuron	Parameter LSTM	Parameter GRU	Selisih	Rasio GRU/LSTM
10	851	671	180	0,7885
20	2.501	1.941	560	0,7761
30	4.951	3.811	1.140	0,7697
40	8.201	6.281	1.920	0,7659
50	12.251	9.351	2.900	0,7633

Pada jumlah *neuron* yang sama, GRU konsisten membutuhkan sekitar tiga perempat parameter LSTM karena hanya memiliki tiga himpunan bobot. Selanjutnya, untuk memastikan bahwa hasil perbandingan bukan kebetulan akibat inisialisasi bobot acak, konfigurasi terbaik masing-masing model dilatih ulang dengan lima *seed* berbeda. Hasil uji kestabilan disajikan pada Tabel 28.

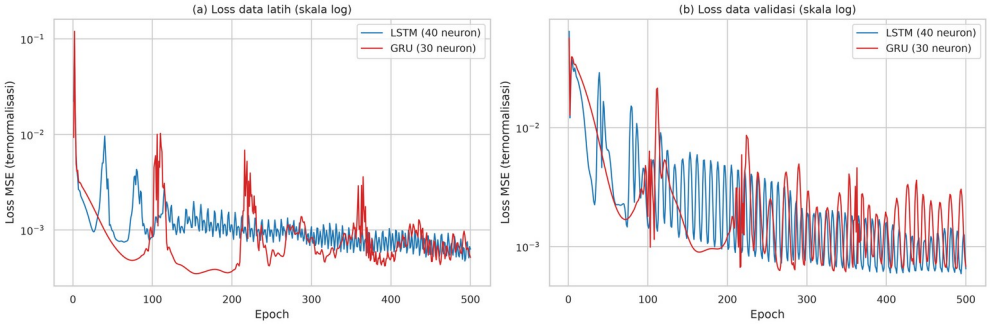
Tabel 28. Hasil Uji Kestabilan Model terhadap Lima *Seed*

Model	*Seed*	RMSE Uji (USD)	MAE Uji (USD)	MAPE Uji (%)	Akurasi Arah (%)
LSTM	42	2.045,51	1.525,74	2,1061	49,12
LSTM	7	5.943,13	5.632,59	7,8321	48,23
LSTM	21	3.863,43	3.422,23	4,7500	48,23
LSTM	100	3.550,75	3.082,93	4,2672	48,23
LSTM	2024	2.949,85	2.463,34	3,4155	48,23
GRU	42	2.009,65	1.468,24	2,0476	51,33
GRU	7	2.032,63	1.527,43	2,1210	44,69
GRU	21	2.597,92	2.005,72	2,7384	47,35
GRU	100	5.709,49	5.418,62	7,5800	48,23
GRU	2024	4.269,23	3.841,30	5,4450	48,23
LSTM	Rata-rata ± Std	**3.670,54 ± 1.447,10**		**4,4742 ± 2,1285**	48,41
GRU	Rata-rata ± Std	**3.323,79 ± 1.620,68**		**3,9864 ± 2,4412**	47,96



Gambar 13. Sebaran RMSE Data Uji pada Lima *Seed*

Berdasarkan Tabel 28 dan Gambar 13, GRU menghasilkan RMSE lebih kecil pada tiga *seed* (42, 7, dan 21), sedangkan LSTM lebih kecil pada dua *seed* (100 dan 2024). Rata-rata RMSE GRU (3.323,79 USD) lebih kecil daripada LSTM (3.670,54 USD), tetapi selang rata-rata ± satu standar deviasi kedua model saling tumpang tindih (LSTM 2.223,44 sampai 5.117,63 USD; GRU 1.703,11 sampai 4.944,46 USD). Artinya, kinerja kedua model cukup sensitif terhadap inisialisasi bobot acak dan keunggulan GRU belum dapat disebut sistematis. Pelatihan ulang dengan *seed* 42 menghasilkan prediksi yang sama persis dengan pelatihan awal (selisih maksimum 0 USD), sehingga seluruh hasil penelitian dapat direproduksi. Perbandingan proses belajar kedua model ditunjukkan pada Gambar 14.



Gambar 14. Perbandingan Kurva *Loss* Model LSTM dan GRU

Pada *epoch* ke-10, *loss* latih LSTM sebesar 0,002258 dan GRU 0,003042, sehingga LSTM menurunkan *loss* lebih cepat pada awal pelatihan. Pada akhir pelatihan, *loss* latih GRU (0,000517) lebih kecil daripada LSTM (0,000631), sedangkan *loss* validasi LSTM (0,000650) sedikit lebih kecil daripada GRU (0,000682).

3.6 Denormalisasi Hasil Prediksi

Tahap denormalisasi mengembalikan hasil prediksi yang masih berada pada skala ternormalisasi ke skala harga asli (USD) menggunakan persamaan (8) dengan $x_{1,\min} = 25.162{,}70$ dan $x_{1,\max} = 123.359{,}45$ yang berasal dari data latih. Berikut contoh perhitungan denormalisasi prediksi tanggal 18 Desember 2025:

$$\hat{y}_{\text{LSTM}} = 0{,}642306 \times (123.359{,}45 - 25.162{,}70) + 25.162{,}70 = 63.072{,}39 + 25.162{,}70 = 88.235{,}09$$
$$\hat{y}_{\text{GRU}} = 0{,}647681 \times (123.359{,}45 - 25.162{,}70) + 25.162{,}70 = 63.600{,}22 + 25.162{,}70 = 88.762{,}92$$

Hasil perhitungan manual tersebut identik dengan keluaran inverse_transform pada pustaka scikit-learn. Harga aktual pada tanggal tersebut adalah 86.132,82 USD, sehingga galat LSTM sebesar $86.132{,}82 - 88.235{,}09 = -2.102{,}27$ USD dan galat GRU sebesar $-2.630{,}10$ USD. Tanda negatif menunjukkan bahwa kedua model memprediksi harga lebih tinggi daripada harga aktual (*overestimate*). Sampel hasil prediksi setelah denormalisasi disajikan pada Tabel 29.

Tabel 29. Hasil Prediksi Model LSTM dan GRU Setelah Denormalisasi

Tanggal	Aktual (USD)	Prediksi LSTM (USD)	Prediksi GRU (USD)	Galat LSTM (USD)	Galat GRU (USD)
18/12/2025	86.132,82	88.235,09	88.762,92	-2.102,27	-2.630,10
19/12/2025	85.458,35	86.359,86	87.246,46	-901,51	-1.788,11
20/12/2025	88.098,82	85.962,64	87.038,05	2.136,17	1.060,77
21/12/2025	88.337,41	87.684,05	88.649,40	653,36	-311,99
22/12/2025	88.615,72	87.909,55	88.845,88	706,17	-230,16
…	…	…	…	…	…
27/07/2026	65.335,46	62.187,64	62.640,98	3.147,82	2.694,48
28/07/2026	63.710,94	64.104,31	63.448,42	-393,37	262,52
29/07/2026	63.873,46	62.717,71	62.494,74	1.155,75	1.378,72
30/07/2026	63.897,36	62.677,69	62.000,36	1.219,67	1.897,00
31/07/2026	64.720,99	62.368,96	62.211,63	2.352,03	2.509,36

Hasil prediksi lengkap untuk 226 hari data uji disajikan pada Lampiran 2.

3.7 Perhitungan Nilai Akurasi Prediksi

Pada tahap ini dihitung nilai galat hasil prediksi menggunakan RMSE, MAE, MAPE, dan akurasi arah sesuai persamaan (32) sampai (35). Berikut contoh perhitungan galat pada tanggal 18 Desember 2025 untuk model LSTM:

$$e_1 = y_1 - \hat{y}_1 = 86.132{,}82 - 88.235{,}09 = -2.102{,}27$$

$$e_1^2 = (-2.102{,}27)^2 = 4.419.556{,}89$$

$$\left|\frac{e_1}{y_1}\right| \times 100\,\% = \left|\frac{-2.102{,}27}{86.132{,}82}\right| \times 100\,\% = 2{,}4407\,\%$$

Perhitungan yang sama dilakukan untuk setiap hari pada data uji. Rincian galat tiga hari pertama dan hari terakhir disajikan pada Tabel 30.

Tabel 30. Rincian Perhitungan Galat Hari Pertama sampai Ketiga dan Hari Terakhir Data Uji

Model	Tanggal	Aktual y_t	Prediksi $\hat{y}_t$	e_t	e_t^2	APE (%)
LSTM	18/12/2025	86.132,82	88.235,09	-2.102,27	4.419.556,89	2,4407
LSTM	19/12/2025	85.458,35	86.359,86	-901,51	812.712,37	1,0549
LSTM	20/12/2025	88.098,82	85.962,64	2.136,17	4.563.242,32	2,4247
LSTM	31/07/2026	64.720,99	62.368,96	2.352,03	5.532.057,75	3,6341
GRU	18/12/2025	86.132,82	88.762,92	-2.630,10	6.917.405,87	3,0535
GRU	19/12/2025	85.458,35	87.246,46	-1.788,11	3.197.335,71	2,0924
GRU	20/12/2025	88.098,82	87.038,05	1.060,77	1.125.222,95	1,2041
GRU	31/07/2026	64.720,99	62.211,63	2.509,36	6.296.877,19	3,8772

Setelah seluruh 226 hari dihitung, nilai metrik evaluasi untuk model LSTM diperoleh sebagai berikut. Urutan perhitungan RMSE adalah mengkuadratkan galat, merata-ratakan, lalu mengakarkan hasilnya:

$$\text{RMSE}_{\text{LSTM}} = \sqrt{\frac{4.419.556,89 + 812.712,37 + 4.563.242,32 + \cdots + 5.532.057,75}{226}}$$

$$= \sqrt{\frac{945.609.870,08}{226}} = \sqrt{4.184.114,47} = 2.045,51$$

$$\text{MAE}_{\text{LSTM}} = \frac{2.102,27 + 901,51 + 2.136,17 + \cdots + 2.352,03}{226}$$

$$= \frac{344.816,41}{226} = 1.525,74$$

$$\text{MAPE}_{\text{LSTM}} = \frac{2,4407\,\% + 1,0549\,\% + 2,4247\,\% + \cdots + 3,6341\,\%}{226}$$

$$= \frac{475,9864\,\%}{226} = 2,1061\,\%$$

Dengan cara yang sama, nilai metrik evaluasi untuk model GRU adalah:

$$\text{RMSE}_{\text{GRU}} = \sqrt{\frac{912.748.765{,}13}{226}} = \sqrt{4.038.711{,}35} = 2.009{,}65$$

$$\text{MAE}_{\text{GRU}} = \frac{331.821{,}47}{226} = 1.468{,}24$$

$$\text{MAPE}_{\text{GRU}} = \frac{462{,}7540\,\%}{226} = 2{,}0476\,\%$$

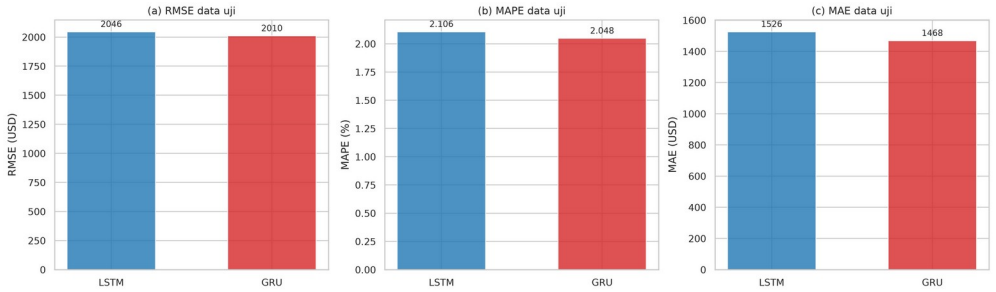
Akurasi arah dihitung dengan membandingkan arah perubahan harga aktual dan arah prediksi terhadap harga aktual hari sebelumnya. Pada hari pertama, harga aktual turun dari 87.835,39 USD menjadi 86.132,82 USD, sedangkan kedua model memprediksi kenaikan sehingga arahnya tidak cocok. Pada hari ketiga, harga aktual naik dari 85.458,35 USD menjadi 88.098,82 USD dan kedua model juga memprediksi kenaikan sehingga arahnya cocok. Dari 226 hari, arah LSTM tepat pada 111 hari dan GRU pada 116 hari:

$$\text{DA}_{\text{LSTM}} = \frac{111}{226} \times 100\,\% = 49{,}1150\,\%, \text{DA}_{\text{GRU}} = \frac{116}{226} \times 100\,\% = 51{,}3274\,\%$$

Hasil perhitungan manual seluruh metrik identik dengan fungsi pada modul metrik.py hingga toleransi 10^{-5}. Perbandingan nilai akurasi prediksi kedua model disajikan pada Tabel 31.

Tabel 31. Nilai Akurasi Prediksi Model LSTM dan GRU pada Data Uji

Metrik	LSTM	GRU	Lebih Baik
RMSE (USD)	2.045,51	2.009,65	GRU
MAE (USD)	1.525,74	1.468,24	GRU
MAPE (%)	2,1061	2,0476	GRU
Kategori MAPE	Sangat Akurat	Sangat Akurat	–
Akurasi Arah (%)	49,1150	51,3274	GRU
Jumlah parameter	8.201	3.811	GRU
Waktu latih per *epoch* (detik)	0,1591	0,1661	LSTM



Gambar 15. Perbandingan RMSE, MAPE, dan MAE Model LSTM dan GRU

Berdasarkan Tabel 31 dan Gambar 15, GRU unggul tipis pada ketiga metrik galat. Selisih RMSE kedua model hanya 35,86 USD atau 1,75%, sedangkan selisih

MAPE hanya 0,0585 poin persentase. Nilai MAPE kedua model berada di bawah 10% sehingga termasuk kategori sangat akurat (Tabel 3). Namun, akurasi arah kedua model hanya sekitar 49% sampai 51%, atau setara dengan menebak arah secara acak. Hal ini menunjukkan bahwa kedua model mampu mengikuti tingkat (*level*) harga dengan baik, tetapi tidak mampu memprediksi arah kenaikan atau penurunan harga pada hari berikutnya.

3.8 Uji Signifikansi Diebold-Mariano

Untuk mengetahui apakah selisih akurasi LSTM dan GRU bermakna secara statistik, dilakukan uji Diebold-Mariano dengan fungsi *loss* kuadrat, horizon $h=1$, dan taraf signifikansi $\alpha=5\%$. Hipotesis yang diuji adalah:

$$H_0: E\left[d_t\right]=0 \text{ (akurasi LSTM dan GRU sama)}, H_1: E\left[d_t\right]\neq 0 \text{ (akurasi berbeda)}$$

Langkah pertama adalah menghitung selisih *loss* d_t setiap hari menggunakan persamaan (36). Enam hari pertama dan hari terakhir disajikan pada Tabel 32.

Tabel 32. Selisih *Loss* Kuadrat LSTM dan GRU

t	**Tanggal**	$e_{L,t}$	$e_{G,t}$	$e_{L,t}^2$	$e_{G,t}^2$	d_t
1	18/12/2025	-2.102,27	-2.630,10	4.419.556,89	6.917.405,87	-2.497.848,98
2	19/12/2025	-901,51	-1.788,11	812.712,37	3.197.335,71	-2.384.623,34
3	20/12/2025	2.136,17	1.060,77	4.563.242,32	1.125.222,95	3.438.019,37
4	21/12/2025	653,36	-311,99	426.875,00	97.339,77	329.535,23
5	22/12/2025	706,17	-230,16	498.681,76	52.974,86	445.706,91
6	23/12/2025	-577,99	-539,62	334.069,97	291.191,43	42.878,54
⋮	⋮	⋮	⋮	⋮	⋮	⋮
226	31/07/2026	2.352,03	2.509,36	5.532.057,75	6.296.877,19	-764.819,45

Dari 226 hari, terdapat 100 hari dengan $d_t<0$ (LSTM lebih akurat) dan 126 hari dengan $d_t>0$ (GRU lebih akurat). Selanjutnya statistik uji dihitung menggunakan persamaan (37) sampai (42):

$$\bar{d} = \frac{32.861.104{,}94}{226} = 145.403{,}12$$

$$\gamma_0 = \frac{1}{226}\left[(-2.497.848{,}98 - 145.403{,}12)^2 + (-2.384.623{,}34 - 145.403{,}12)^2 + \cdots\right]$$

$$= \frac{2.324.328.756.613.639{,}50}{226} = 10.284.640.515.989{,}55$$

$$\hat{V}(\bar{d}) = \frac{\gamma_0}{T} = \frac{10.284.640.515.989{,}55}{226} = 45.507.258.920{,}31$$

$$DM = \frac{145.403{,}12}{\sqrt{45.507.258.920{,}31}} = \frac{145.403{,}12}{213.324{,}30} = 0{,}681606$$

$$\mathrm{DM}^* = 0{,}681606 \times \sqrt{\frac{226 + 1 - 2(1) + 0}{226}} = 0{,}681606 \times 0{,}997785 = 0{,}680096$$

$$p = 2\left[1 - F_{225}(0{,}680096)\right] = 0{,}497143$$

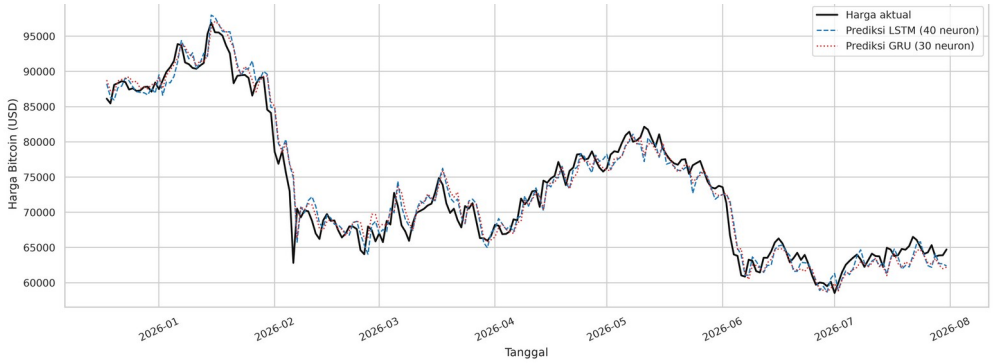
Tabel 33. Hasil Uji Diebold-Mariano LSTM dan GRU

Komponen	Nilai
Jumlah pengamatan (T)	226
Rata-rata selisih *loss* ($\bar{d}$)	145.403,12
Statistik DM (tanpa koreksi)	0,681606
Faktor koreksi Harvey-Leybourne-Newbold	0,997785
Statistik DM^*	0,680096
Derajat bebas	225
Nilai kritis $t_{(0{,}975;\,225)}$	± 1,970563
p-value	0,497143
Keputusan	Gagal tolak H_0

Nilai $\bar{d}$ yang positif menunjukkan bahwa rata-rata *loss* kuadrat LSTM sedikit lebih besar daripada GRU. Namun, karena $|\mathrm{DM}^*| = 0{,}680096 < 1{,}970563$ dan *p-value* $= 0{,}497143 > 0{,}05$, maka H_0 gagal ditolak. Dengan demikian, perbedaan akurasi LSTM dan GRU tidak signifikan secara statistik pada taraf 5%, sehingga kedua model dapat dianggap memiliki akurasi yang setara. Hasil ini sejalan dengan uji kestabilan pada Subbab 3.5 yang menunjukkan bahwa urutan keunggulan kedua model berganti-ganti antar-*seed*.

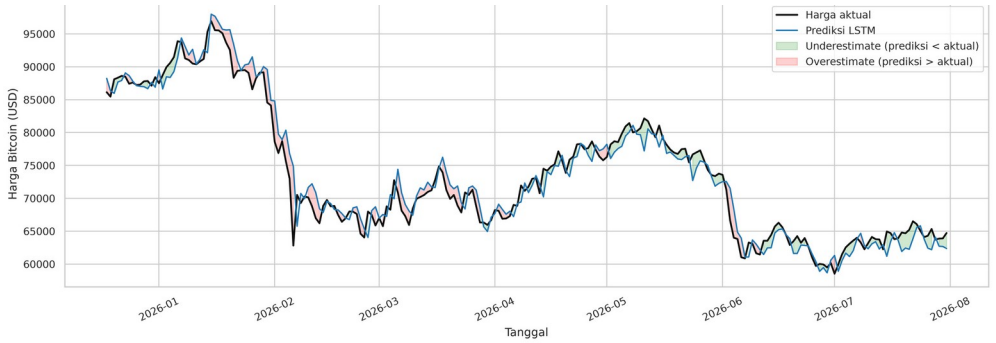
3.9 Hasil Visualisasi Prediksi

Grafik perbandingan antara harga aktual dan hasil prediksi kedua model pada data uji disajikan pada Gambar 16.

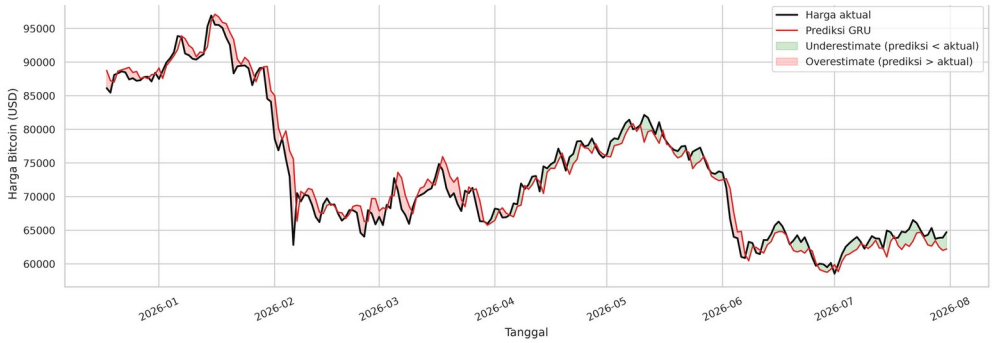


Gambar 16. Grafik Perbandingan Harga Aktual dan Prediksi Model LSTM dan GRU

Secara visual, kedua kurva prediksi mengikuti pergerakan harga aktual dengan pola yang hampir identik sepanjang periode 18 Desember 2025 hingga 31 Juli 2026, baik pada fase kenaikan pertengahan Januari 2026, penurunan tajam awal Februari 2026, pemulihan hingga Mei 2026, maupun penurunan pada Juni 2026. Kedua kurva prediksi tampak tergeser sekitar satu hari di belakang harga aktual karena model sangat bergantung pada harga hari-hari terakhir dalam *window*, sehingga lonjakan mendadak baru "tersusul" pada hari berikutnya. Pola kesalahan masing-masing model ditunjukkan pada Gambar 17 dan Gambar 18.



Gambar 17. Harga Aktual dan Prediksi Model LSTM pada Data Uji



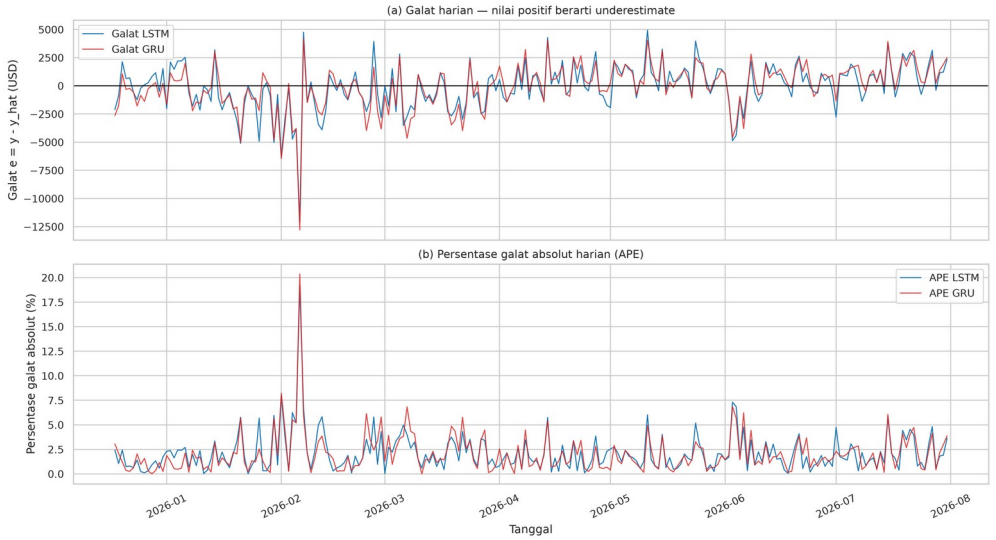
Gambar 18. Harga Aktual dan Prediksi Model GRU pada Data Uji

Area hijau menunjukkan hari ketika model memprediksi lebih rendah daripada harga aktual (*underestimate*), sedangkan area merah menunjukkan hari ketika model memprediksi lebih tinggi (*overestimate*). LSTM mengalami *underestimate* pada 49,12% hari uji dan GRU pada 54,42% hari uji, sehingga tidak terdapat bias sistematis yang kuat ke salah satu arah. Kinerja kedua model menurut kondisi pasar disajikan pada Tabel 34.

Tabel 34. Kinerja Model Menurut Kondisi Pasar pada Data Uji

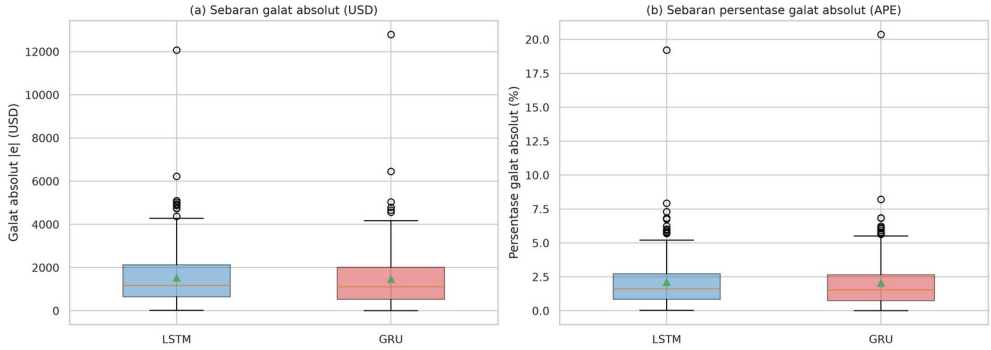
Kondisi Pasar	Jumlah Hari	MAE LSTM (USD)	MAE GRU (USD)
Naik tajam (> +2% per hari)	28	2.100,88	2.024,52
Turun tajam (< −2% per hari)	35	2.774,76	2.789,11
Relatif stabil (−2% s.d. +2%)	163	1.158,74	1.089,06

Kesalahan kedua model membesar pada hari-hari bergejolak. MAE LSTM meningkat dari 1.158,74 USD pada kondisi pasar relatif stabil menjadi 2.475,26 USD pada hari ketika harga bergerak lebih dari 2% dalam sehari. GRU sedikit lebih baik pada kondisi stabil dan kenaikan tajam, sedangkan LSTM sedikit lebih baik pada penurunan tajam. Galat harian kedua model ditunjukkan pada Gambar 19.



Gambar 19. Galat Harian Model LSTM dan GRU pada Data Uji

Kedua garis galat bergerak hampir berimpit dengan koefisien korelasi 0,9320, artinya LSTM dan GRU keliru pada hari-hari yang sama. Galat terbesar kedua model terjadi pada 6 Februari 2026, yaitu $-12.063{,}68$ USD untuk LSTM dan $-12.792{,}27$ USD untuk GRU. Pada hari tersebut harga aktual anjlok dari 73.004,18 USD menjadi 62.812,06 USD, sedangkan kedua model masih memprediksi harga yang dekat dengan harga hari sebelumnya. Sebaran galat absolut kedua model ditunjukkan pada Gambar 20 dan Tabel 35.



Gambar 20. *Boxplot* Galat Absolut Model LSTM dan GRU

Tabel 35. Statistik Galat Absolut Model LSTM dan GRU

Statistik	$\lvert e_t \rvert$ LSTM (USD)	$\lvert e_t \rvert$ GRU (USD)
Minimum	14,60	3,63
Kuartil 1	642,60	531,03
Median	1.169,53	1.110,44
Rata-rata	1.525,74	1.468,24
Kuartil 3	2.123,70	2.006,59
Maksimum	12.063,68	12.792,27

Median galat absolut LSTM sebesar 1.169,53 USD dan GRU sebesar 1.110,44 USD dengan kotak yang saling tumpang tindih, sehingga sebaran kesalahan kedua model praktis setara. Rata-rata galat yang lebih besar daripada median menunjukkan sebaran galat menjulur ke kanan akibat beberapa hari bergejolak dengan galat yang sangat besar.